



深圳技术大学

SHENZHEN TECHNOLOGY UNIVERSITY

本科毕业论文（设计）

题目：基于深度学习的胎儿心率分析
增强及基线自动确定

姓 名	李乐雅
学 院	大数据与互联网学院
专 业	物联网工程
学 号	202002010104
指 导 教 师	吕羽
职 称	副教授
提 交 日 期	2024 年 5 月 18 日

深圳技术大学本科毕业论文（设计）诚信声明

本人郑重声明：所呈交的毕业论文（设计），题目《基于深度学习的胎儿心率分析增强及基线自动确定》是本人在指导教师的指导下，独立进行研究工作所取得的成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式注明。除此之外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。本人完全意识到本声明的法律结果。

毕业论文（设计）作者签名：李东雅

日期：2024年5月18日

目录

摘要.....	I
Abstract	II
符号与缩略语说明.....	IV
1. 引言.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.3 主要研究内容.....	3
1.4 章节安排.....	4
2. 胎心宫缩信号及深度学习相关基础和理论	6
2.1 胎心宫缩监理论.....	6
2.1.1 胎心宫缩信号采集方式.....	6
2.1.2 胎心宫缩信号基本特征.....	8
2.1.3 胎心宫缩信号状态分类.....	10
2.2 深度神经网络模型介绍.....	11
2.2.1 卷积层.....	12
2.2.2 池化层.....	13
2.2.3 编码器与解码器.....	14
2.3 本章小结.....	15
3. 基于深度神经网络的基线确定算法研究	17

3.1 研究流程设计	17
3.2 实验数据预处理	17
3.2.1 数据集介绍	17
3.2.2 数据异常值预处理	19
3.2.3 数据增强方法	20
3.3 算法模型设计	21
3.4 本章小结	23
4. 实验与分析	25
4.1 性能评估指标	25
4.2 与其他方法对比	27
4.2.1 其他方法介绍	27
4.2.2 实验设置	28
4.2.3 实验结果对比分析	29
4.3 消融实验	31
4.3.1 实验设计	31
4.3.2 结果分析	31
4.4 本章小结	33
5. 总结与展望	35
参考文献	36
致谢	41
攻读学士学位期间研究成果	42

基于深度学习的胎儿心率分析增强及基线自动确定

【摘要】胎心率是评估胎儿健康的重要指标，产科医生对胎心率的视觉解读取决于对胎心率模式的识别。计算机辅助胎心率分析可以有效解决医生之间的诊断不一致和医生前后诊断不一致问题，有效提高胎儿的诊断效率和诊断精度。对诊断而言，精确的胎心率模式检测时精准诊断的基础也是目前计算机辅助分析的主要挑战之一。本研究旨在提出一种增强胎心率分析并且自动确定胎心率基线的方法，来解决上述问题。

本研究提出了一种融合能够提取多尺度特征进行信号分割的深度神经网络模型 MseUNet，原始胎心率信号去除 MseUNet 检测到的加减速点后，使用结合长短期中值滤波得到维持连续性和稳定性的胎心率基线。MseUNet 由一个编码器和一个相应的解码器组成，解码器输出多通道数据，用于根据输入的胎心率信号进行加速/减速/基线模式的分割。

法国里尔天主教大学的开放数据库中带标签的训练数据用于训练以及测试模型效果。实验结果表明，该方法所确定的基线与专家绘制的基线差异平均在 3.20 bpm，超越了传统的 11 种方法，且对减速的识别达到目前最优性能。此外，本研究为确定模型的泛化能力，还引入的 CTU-CHB 数据集测试模型，在该数据集上，本研究提出的方法有可靠的表现。

本文所提出的用于分割胎心率信号加速/减速/基线模式，确定胎心率基线，增强胎心率自动分析的 MseUNet 实现了高水平的性能。

【关键词】胎心率基线确定；U-Net；多尺度特征提取；中值滤波；胎儿窘迫诊断

Enhancing Fetal Heart Rate Analysis with Deep Learning for Automatic Determination of Baseline

【Abstract】 Fetal heart rate is an important indicator for assessing fetal health, and the visual interpretation of fetal heart rate by obstetricians depends on the recognition of fetal heart rate patterns. Computer-assisted fetal heart rate analysis can effectively solve the problem of diagnostic inconsistency between doctors and inconsistency between doctors' pre- and post-diagnosis, and effectively improve the efficiency and diagnostic accuracy of foetal diagnosis.

For diagnosis, accurate fetal heart rate pattern detection is the basis of accurate diagnosis and one of the main challenges of computer-aided analysis at present. The aim of this study is to propose a method that enhances fetal heart rate analysis and automatically determines the baseline of fetal heart rate to solve the above problems.

In this study, a deep neural network model, MseUNet, is proposed, which incorporates a deep neural network model capable of extracting multi-scale features for signal segmentation. the raw fetal heart rate signal is removed from the acceleration and deceleration points detected by MseUNet, and then combined with a short- and long-term median filtering is used to obtain the baseline of the fetal heart rate that maintains the continuity and stability of the fetal heart rate. MseUNet consists of an encoder and an accompanying decoder, which outputs multi-channel data for acceleration/deceleration/baseline mode segmentation based on the input fetal heart rate signal.

Labelled training data from the open database of the Catholic University of Lille, France, are used to train as well as test the model effects. The experimental results show that the difference between the baseline identified by the method and the expert-drawn baseline is on average 3.20 bpm, which outperforms the 11 traditional methods and

achieves the current optimal performance for the recognition of slowdowns. In addition, the CTU-CHB dataset, which was introduced in this study to test the model in order to determine the generalisation ability of the model, is the dataset on which the method proposed in this study performs reliably.

The MseUNet proposed in this paper for segmenting the acceleration/deceleration/baseline patterns of the fetal heart rate signal, determining the baseline of the fetal heart rate, and enhancing the automated analysis of the fetal heart rate achieves a high level of performance.

【Key words】 FHR baseline determination; U-Net; multi-scale feature extraction; median filtering; fetal distress diagnosis

符号与缩略语说明

EFM	电子胎心监护 (Electronic Fetal Monitoring)
CTG	胎心图 (Cardiotocography)
FHR	胎心率 (Fetal Heart Rate)
UC	宫缩 (Uterine Contraction)
STFT	短时傅里叶变换 (Short Time Fourier Transform)
DCNN	深度卷积神经网络 (Deep Convolutional Neural Networks)
1D-CNN	一维卷积神经网络 (1D Convolutional Neural Network)
LSTM	长短期记忆递归神经网络 (Long Short-Term Memory)
GRU	门控循环单元 (Gate Recurrent Unit)
BN	批量归一化 (Batch Normalization)
ReLU	线性修正单元 (Rectified Linear Unit)

1. 引言

1.1 研究背景及意义

新生儿的健康分娩对社会的长期繁荣和可持续发展具有重要意义。随着出生率下降，一些国家正面临人口老龄化和人口减少的挑战。通过提供优质的分娩服务和确保新生儿健康，可以维持人口平衡，保障未来的劳动力供应和社会的持续发展。尽管现代医疗技术发展迅速，但是婴儿的死亡率仍时全球医疗保健系统的正面临的重大挑战。妊娠期间，胎儿可能受到多方面的影响，遭到神经发育问题，如非行走性脑瘫，生长迟缓，听觉和视觉障碍，有时甚至死亡。因此医护人员需要使用额外的方法来筛查和测量胎儿的健康状况。

胎儿心率是评估胎儿健康状况的重要指标之一。正常的胎儿心率可以提供胎儿没有遭受缺氧或其他健康问题的初步信号，异常的胎儿心率可能预示着某些并发症，如胎儿窘迫、胎盘早剥、脐带压迫等，这些情况需要立即的医疗干预。同时，在分娩过程中监测胎儿心率可以帮助医生决定是否需要采取特定的干预措施，如使用产钳、吸盘或进行剖宫产。

电子胎心率监测（EFM），特别是心电监护图（Cardiotocography, CTG）是监测胎儿心率的一种重要手段。EFM 最初成功设计用于预防死胎，后期将扩展 EFM 的应用，以预测和预防胎儿酸中毒及其后果^[1]。在临床实践中，有五个基本参数用于识别胎儿缺氧，其中高于或低于基线 15bpm 超过 15s 的采样点被定义为胎心率加速和胎心率减速^[2]，可见基线是确定胎儿在子宫内安全的重要依据。减速在参考宫缩起始时间下还能分为三种类型，分别对应不同的健康状态。然而，每条 CTG 记录通常持续 30 分钟到 1 小时不等，胎心率基线、加速和减速这些模式通常由妇科医生和产科医生进行视觉解释，观察者之间和观察者内部存在显著的差异性和解读不可靠性^[3]，这让人工精准地确定胎心率基线充满挑战。所以，科研人员尝试使用自动胎心率分析取代观察者人工解释的方法，通过自动分析推断出胎儿的状态，例如正常或缺氧。

不仅在临床方面，胎心率自动化分析研究在其他方面也有着不可忽视的意义。

胎儿心率的模式可以提供关于胎儿成熟度的信息，通过长期的研究，可以更好地了解胎儿心率变化与胎儿发育之间的关系，包括大脑和神经系统的发育。胎儿心率的异常可能与妊娠期疾病（如妊娠高血压、糖尿病等）有关，研究有助于更好地理解这些疾病的机制。就医学教育而言，清晰的可解释的胎心率分析能够辅助医学生和住院医师学习解读胎心率，有助于学生理解胎儿生理学和病理学。

可见，胎儿心率监测的分析增强和基线自动确定对于提升医疗护理质量、优化临床决策、降低新生儿并发症风险、辅助医学教育和专业培训以及推动围生期医学研究等领域均具有极其重要的意义，对于保障母亲和婴儿的健康、推动医疗技术发展、维护社会经济的稳定和促进人口的可持续发展均发挥着关键作用。

1.2 国内外研究现状

胎心率和子宫收缩的变化对于胎儿健康状况的分类至关重要，但是 CTG 的结果评价实际上非常依赖于产科医生的经验和主观判断，导致同一 CTG 的结果不同。对于孕妇来说，胎心率监测可以从怀孕 32 周开始，高危孕妇可以提前 26 至 28 周开始。但即使是低危孕妇，也建议每周监测一到两次，导致产科医生工作量巨大，误判率较高。

所以自动分析算法被考虑用于代替人工分析，减少主观性带来的误差。与传统的信号处理或机器学习算法相比，深度学习将使特征提取更加简单，避免了很多人工错误判读，提高了准确性和诊断效率。CöMert 等人^[4]利用 CTU-CHB 的开源数据集，通过短时傅里叶变换（STFT）将胎心率转换为频域图像，然后使用 DCNN 对胎儿健康状况进行分类。Li 等人^[5]划分胎心率信号分为十个窗口，然后要求它通过 1D-CNN 对每个窗口进行投票，以对胎儿状态进行分类。Fergus 等人^[6]提出了一种加窗策略来处理不平衡的胎心率数据集并使用 1D-CNN 进行分类。Lv 等人^[7]已经使用循环神经网络长短期记忆（LSTM）根据同是生物时间序列的心电信号成功地预测了各种心电图疾病。Liang 等人^[8]提出一种基于一维卷积神经网络（1D-CNN）和门控循环单元（GRU）的混合模型，用于分析胎心监护设备获取的胎心率和宫缩信号，以评估胎儿健康状况。

但是，深度神经网络模型是一种“黑盒”模型，模型判断的结果往往是缺乏解释的，为了提高胎心宫缩信号自动分析诊断的可信度，胎心率基线是胎心宫缩信号异常情况判断的重要依据，所以一个能精准识别胎心率模式的方法在胎心率自动分析增强方面有重要意义。

目前，已经有许多团队提出了胎心率状态识别的解决方案。其中，滤波是确定基线的典型处理方法。研究人员们已经开发了各种滤波器，例如低通滤波器^[9-13]、中值滤波器^[14-16]和其他滑动滤波器^[17-19]。但是由于低通滤波器存在不可避免的边界振荡和事故拖尾问题，所以这些方法无法完全过滤掉潜在的事故（意外的加速/减速）。此外，中值滤波器或其他滑动滤波器会忽略不显着的事故模式，例如延长的减速、比基线周期长的稳定事故周期等。对于复杂的胎心率情况，尤其事故和基线交替出现的情况下，使用滤波器依靠中值或最高频率值来确定局部基线水平将导致整体基线水平的忽视并错误地检测加速模式或者减速模式。

渐进式修剪的方法通过多重滤波改进了基线估计，但局限于初始基线的确定。当加速或减速模式稀疏即大部分时间段胎心率处于基线模式，且初始基线接近真实基线时，可以获得较为准确的基线。然而，在加速或减速模式较多的情况下，如果不利用初始基线来正确判断加减速速度，逐步微调会进一步加剧偏差。此外，渐进修剪的基线估计步骤主要使用基于滤波的方法^[9,10,13]，这意味着滤波器性能可能限制着渐进修剪所确定的基线的准确程度。因此，当加减速模式分辨的准确度足够高时，就可以计算出更贴近真实值的基线，进而进行渐进式修剪优化短时间段内的基线值。

1.3 主要研究内容

如上所述，这些传统方法依赖于有限的滤波器的性能，难以解决具有复杂加速/减速模式分布的临床病例。在实践中，临床医生在估计基线时倾向于结合加速/减速的形态，这导致计算机根据规则辅助判断和专家的经验判断之间存在不可忽视的偏差^[20]。深度学习算法捕捉时序形态信息的能力可以有效提高加减速定位的精度，训练中使用的大型数据集有望增强它们处理复杂胎心率的稳健性。

本文的研究目标在于探索一种基于深度学习的自动胎心率基线确定算法。研究旨在通过深度学习技术对胎心率基线进行确定，从而达到胎心监护信号加减速模式分析增强，以辅助产科医生在临床场景下做出更准确的胎儿健康状况评估。

为实现这一目标，本研究进行了充分的文献综述，深度挖掘神经网络模型在胎心宫缩信号自动分析的潜在应用场景。在数据收集阶段，本研究使用了 CULF-DB 数据库，该数据集包含 66 个时长为 40-120 分钟胎心监护信号。为提高信号的质量，本文首先对数据进行异常值删除、插值等预处理，再用于训练深度神经网络。根据胎心率基线的循环定义，本研究所提出了一种创新的结合多尺度特征融合的改良 U-Net 模型——MseUNet，模型输出结果为信号中每个采样点的模式。在此之后，提出一种结合长短周期滤波技术的胎心率确定方法，该方法考虑了基线连续性和稳定性，得到更符合胎心率基线形态学特征的结果。同时，本研究设计了对比实验、泛化测试以及消融实验，采取了五个不一致指标，从全局和局部方面评估，分析模型的性能以及各模块存在的必要性和有效性。

本文的创新点包括：

(1) 提出了一种结合多尺度特征融合的改良 U-Net 模型 (MseUNet)，以胎心率信号为输入，对各采样点进行模式分割，增强了信号分析的精确度。

(2) 设计了一种结合长短周期滤波技术的胎心率确定方法，这种方法考虑了基线的连续性和稳定性，提高了基线确定的准确性，为胎儿健康状态评估提供可解释的依据。

1.4 章节安排

本文拟利用深度学习方法对 FHR 信号进行分割和分析，以确定胎儿健康状况这一研究问题展开探讨。

引言部分阐述了本研究的背景和意义，概括了国内外相关领域的研究现状，并明确提出了使用改进的 U-Net 模型进行 FHR 信号分析的研究目标。

第二章对胎心工作监理论及深度学习基础知识进行了系统性介绍，为后续

研究奠定了理论基础。

第三章重点研究了基于深度神经网络的 FHR 信号基线确定算法。该章节详细描述了研究流程设计、数据预处理、算法模型设计以及模型训练方案等关键内容。

第四章对所提方法的性能进行了全面评估。首先给出了评价指标体系，然后与其他相关算法进行了对比实验，使用独立数据集进行泛化测试，并针对核心模型组件进行了消融实验分析。

第五章总结了全文研究成果，并对未来研究方向提出了展望。

此次研究围绕利用深度学习方法对 FHR 信号进行分析这一目标，系统地开展了相关的理论研究和实验验证工作，为进一步提高胎儿健康监测的智能化水平提供了有益参考。

2. 胎心宫缩信号及深度学习相关基础和理论

2.1 胎心宫缩监理论

胎儿心率 (FHR) 和心率变异性被用作胎儿在子宫内健康状况的指标。在常规低风险产前咨询期间,根据可用的技能和资源,通过手持式多普勒设备、DeLee-Hillis 听诊器或 Pinard 喇叭短暂测量胎儿心率,该过程称为间歇听诊 (IA) [21]。

在高风险妊娠和紧急情况下,产科护理和临床医生的决策过程常采用胎心宫缩描记法 (CTG) 收集超过 10 分钟的全面胎心率、宫缩以及胎动数据,并根据有支持临床医生实践的评估指南,如美国国家儿童健康与人类发展研究所 (NICHD) 共识小组 [22] 和国际妇产科联盟 (FIGO) 指南 [5] 来判断胎儿健康状况并指导临床干预。

2.1.1 胎心宫缩信号采集方式

胎心宫缩信号的采集通常涉及以下几种方式:

(1) 外监护 (External Monitoring):

这种方法使用放在母亲腹部的传感器来非侵入性地监测产前和产时胎心率和宫缩情况。例如,US 传感器 (图 2-1) 用于产前和产时胎心率的外部监测。图示超声波换能器将电能转换为超声波,并利用多普勒效应来检测心脏结构的运动。使用时将换能器放置在孕妇腹部,并用环绕腹部的松紧带支撑,指向胎儿心脏。




图 2-1 胎心率体外监护设备: (a) 超声波换能器; (b) 松紧带固定在产妇腹部; (c) 超声波束切入胎儿心脏 [23]

子宫收缩监测仪（图 2-2）用于对产妇子宫收缩进行外部监测。它被放置在产妇腹部靠近子宫底的位置，由环绕腹部的弹力带支撑。子宫收缩推动位于外环内的子宫收缩监测仪中心的传感器，借助应变仪机制测量最大位移的百分比^[24]。




图 2-2 宫缩体外监护设备：（a）宫颈动力计；（b）用弹力带固定在子宫底上的宫颈动力计和超声换能器^[23]

（2）内监护（Internal Monitoring）：

内部 FHR 监测将通过阴道将胎心传感器放置在接近胎儿的位置进行，这样将获得更准确的胎心率读数，如图 2-3 所示。这种采集方式需要宫颈扩张约 2~4 厘米和胎膜破裂能够接触到胎儿所在部位，因此该技术只能在分娩过程中使用。




图 2-3 胎心率体内监护设备：（a）电极；（b）放置在胎儿头皮上的电极；（c）用松紧带固定在母体腿上的连接件，电极的连接线连接在该连接件上^[23]

使用经宫颈插入的宫腔内压力（IUP）导管对 UC 进行内部监测（图 2-4），可提供有关宫缩频率、强度和持续时间以及基础子宫张力的定量信息。插入 IUP 导管引起的并发症极为罕见，但胎儿损伤、胎盘大出血、子宫穿孔和宫内感染均有报道^[25]，因此不建议在这些或其他情况下常规临床使用 IUP 导管^[26]。




图 2-4 宫缩体内监护设备：(a) IUP 导管；(b) 以及放置在子宫腔内的导管示意图^[23]

(3) 胎动登记 (Registration of foetal movements):

大多数 CTG 监护仪都会在胎动追踪打印输出中记录胎动，胎动可能由孕妇感知并记录在事件标记中，也可能由监护仪自动检测到。

少数型号的胎动监护仪采用了自动检测胎动的技术，利用 US 传感器获取的信号，并采用低通滤波器，可将低频胎动与心脏结构的高频运动分离开来^[27]。虽然只能检测到在超声波束内发生的胎动，但将该技术与实时超声波技术进行比较的研究表明，该技术能识别 90% 以上的主要肢体和脊椎运动^[28,29]。然而，大多数眼球运动、呼吸运动和胎儿四肢的运动都无法记录。

(4) 其他方法:

a. 遥测监护 (Telemetry Monitoring) 是一种无线监测系统，允许母亲在更大的活动范围内进行胎心和宫缩的监测，在产前监护中尤其有用。

b. 掌上型或便携式设备 (Handheld or Portable Devices) 允许在家庭或移动环境中进行胎心监测，通常用于远程监护或低风险妊娠的监测。

本研究的所用的数据集中的胎心宫缩记录由外监护方式采集，除了设备本身采集过程造成的误差，监听过程中，孕妇的呼吸、移动也会在信号记录上产生伪影、噪声或丢失，降低了监护记录的信噪比，因此一定的数据预处理需要被采取。

2.1.2 胎心宫缩信号基本特征

胎心宫缩信号的波形特征对于评估胎儿是否正在经历缺氧或其他并发症至关重要。医疗专业人员会首先根据指南评估 CTG 的基本特征，然后进行总体 CTG

分类，下表所示 NICHD 指南和 FIGO 指南是两种临床常用的诊断与治疗指南。

表 2-1 NICHD 和 FIGO 指南中用于评估胎儿心电图的胎心率特征

	NICHD		FIGO	
基线 (Baseline)	目测确定“静息”心率的平均水平，并在没有胎儿加速、减速和收缩的情况下进行评估。基线心率是 10 分钟间隔内的平均 bpm，正常基线心率范围为 110 至 160 bpm。		最水平且波动较小的胎心率段的平均水平，每 10 分钟估算一次。正常范围在 110 和 160 bpm 之间	
加速度 (Accelerations)	胎心率突然增加。妊娠 32 周之前，加速度应持续至少 10 秒，峰值应高于基线至少 10 bpm。从妊娠 32 周起，加速度应持续超过 15 秒，峰值应高于基线超过 15 bpm。10 分钟或以上的加速被视为基线的变化。		胎心率突然（在 30 秒内达到峰值）高于基线，幅度超过 15 bpm，持续时间超过 15 秒但不到 10 分钟。	
减速 (Decelerations)	胎心率低于基线超过 15 bpm 的短暂发作，持续至少 15 秒。它们被分为早期、晚期或可变类型。		胎心率降低至基线以下，幅度超过 15 bpm，并持续超过 15 秒。	
变异性 (Variability)	围绕基线胎心率每分钟有 3-5 个周期的微小波动。通过估计基线波动的最高峰和最低谷之间每分钟心跳的差异来进行视觉评估，并在 1 分钟片段内进行评估。		指 FHR 信号中的振荡，以 1 分钟段内信号的平均带宽幅度来评估。	
变异等级 (Variability grade)	缺失	振幅不可检测	正常 变异性	带宽幅度为 5-25 bpm
	最小	振幅 0-5 bpm	变异性 降低	基线段中带宽幅度低于 5 bpm 超过 50 分钟，在减速期间超过 3

				分钟
	中等	振幅 6-25 bpm	变异性	带宽值超过 25 bpm,
	显著	振幅超过 25 bpm	增加	持续超过 30 分钟

相比于胎心率，宫缩信号形态上呈钟形，宫缩信号反映了子宫肌肉的收缩情况，宫缩的频率随分娩的进展而增加，宫缩强度反应了子宫肌肉收缩的强度，可以此百年别处分娩活跃期。宫缩期间，子宫肌肉的收缩可能会减少通过胎盘的血流量，从而导致胎儿接收到的氧气和营养暂时减少，进一步在在胎心率的变化上反映。

2.1.3 胎心宫缩信号状态分类

子宫收缩会影响胎儿的血液氧合，导致心率减慢。因此，在胎心率的同时，需要结合其与子宫收缩之间的时间关系分析，确定胎儿的健康状态，尤其是在胎心率减速期间。

早期减速（Early decelerations）：减速较浅、持续时间短的，减速内具有正常的变异性，并且与宫缩同时发生（图 2-5）。这种情况被认为是由胎儿头部受压引起的，并不表明胎儿缺氧或者酸中毒。






图 2-5 早期减速——减速的发生与子宫收缩相对应^[30]

晚期减速（Late decelerations）：逐渐开始和/或逐渐返回到基线的减速和/或在减速期间减小的变异性（图 2-6）。当减速开始/结束与最低点之间经过超过 30 秒时，就会发生逐渐开始和返回。当宫缩得到充分监测时，后期减速会在（宫缩开始后 20 秒以上开始，在顶点后达到最低点，并在宫缩结束后返回到基线。

图 2-6 晚期减速——减速最低点出现在子宫收缩峰值之后^[30]

变异减速 (Variable decelerations): 如图 2-7 所示, 胎心减速行为与宫缩行为之间没有直接的相互影响, 宫缩与胎心率减速行为的时间关系不明确。该减速类型可能反应胎儿脐带受压, 若挤压时间过久, 可能会导致胎儿长期缺氧甚至酸中毒。因此, 当出现变异减速时, 需要注意胎儿的缺氧情况, 及时干预。

图 2-7 胎心率长时间减速, 且与子宫收缩无关^[30]

美国妇产科学院对孕期胎心率特征的评估给出了指导。非压力测试分为反应性测试和非反应性测试。在无应激测试中, 没有酸中毒或神经抑郁的胎儿心率会随着胎动而暂时加快, 这样的反应被认为是胎儿自主功能正常的良好指标。神经健康的早产胎儿的胎心率通常是无反应的, 反应性丧失通常与胎儿睡眠周期有关, 但也可能由中枢神经系统抑制的任何原因引起, 包括胎儿酸中毒。

2.2 深度神经网络模型介绍

深度神经网络 (DNNs) 是机器学习中模拟人脑处理信息方式的算法, 通过多层非线性数据处理单元 (称为神经元) 学习数据表示。这些网络通过反向传播

算法进行训练，利用梯度下降优化网络权重，以最小化误差或损失函数。DNNs 广泛应用于图像和语音识别、自然语言处理等领域，它们能够自动提取特征并进行复杂模式识别。DNNs 在自动分析 FHR 信号中的应用，通过其强大的数据处理和模式识别能力，能够识别和区分正常的胎心率变异性和异常的心率变化，如减速和加速。DNNs 可以学习从大量胎心监护数据中提取的关键特征，进而对可能的胎儿窘迫或缺氧状态进行预测和分类。此外，DNNs 还能够辅助临床决策，比如在分娩过程中判断是否需要紧急干预，从而提高围生期监护的准确性和效率。通过这种方法，DNNs 有助于降低新生儿并发症的风险，并为孕妇提供更安全、更个性化的护理。

2.2.1 卷积层

卷积层（Convolution Layer）是深度神经网络中用于提取输入数据特征的关键部分，由一系列的卷积神经元组成，每个神经元都覆盖输入数据的一个局部区域，并对该区域内的数据进行卷积操作。对图像处理而言输入数据通常是像素矩阵，而对信号而言输入则是一维的时间序列。卷积操作涉及将一个小型的权重矩阵即卷积核滑动覆盖在图像上，然后计算局部区域与卷积核之间的点积。

进行卷积操作时，卷积核只与输入数据的一个局部区域相乘，如图 2-8 所示，这个局部区域称为感受野。卷积核按顺序滑动遍历整个输入图像，对每个局部区域执行点积操作。卷积核的权重在整个输入图像上共享，即相同的权重应用于图像的每个局部区域，网络的参数数量得到减少，网络更高效。

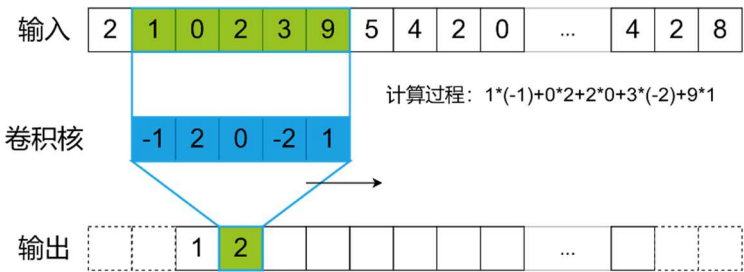


图 2-8 一维卷积核的计算过程

卷积层能将输入数据抽象地表示，从输入数据中提取局部特征，其生成的特征被称为特征映射，捕捉了输入数据的不同特征。卷积核的尺寸（如 3x3、5x5

等)决定了感受野的大小和提取的特征的粒度。步长决定了卷积核滑动的间隔,步长为 1 表示卷积核每次移动一个像素,步长越大特征映射的尺寸越小。填充则是在输入数据边缘添加额外的值,可以以多种模式如线性填充、固定值填充和堆成映射,以控制输出特征映射的尺寸并维持合理的数值。卷积操作的输出通常会通过一个非线性激活函数(如 ReLU)传递,以引入非线性,使神经网络得以学习到更复杂的特征表示。

一维卷积层常用于处理序列数据,如时间序列或音频信号。二维卷积层多用于处理图像数据,卷积核在图像的宽度和高度上操作。三维卷积层一般用于处理体积数据,如视频或三维图像。卷积层是深度学习中用于图像识别、语音识别和其他感知任务的基础,它们使得网络能够自动并有效地从原始数据中学习到有用的特征。

2.2.2 池化层

池化层(Pooling Layer),也称为下采样层(Downsampling Layer),池化操作可以减少特征映射的数量,从而降低后续网络的计算复杂度,提高网络的训练效率,同时学习到对输入数据的平移、缩放和其他变化不变的特征。

池化层通过在输入的特征映射上应用一个固定大小的窗口,并使用一个简单的函数来聚合窗口内的值。如图 2-9 所示,最常用的池化操作包括:

(1) **最大池化(Max Pooling)**: 选择窗口内的最大值作为输出,保留最显著的特征;

(2) **平均池化(Average Pooling)**: 计算窗口内所有值的平均数作为输出,提供平滑的特征表示。

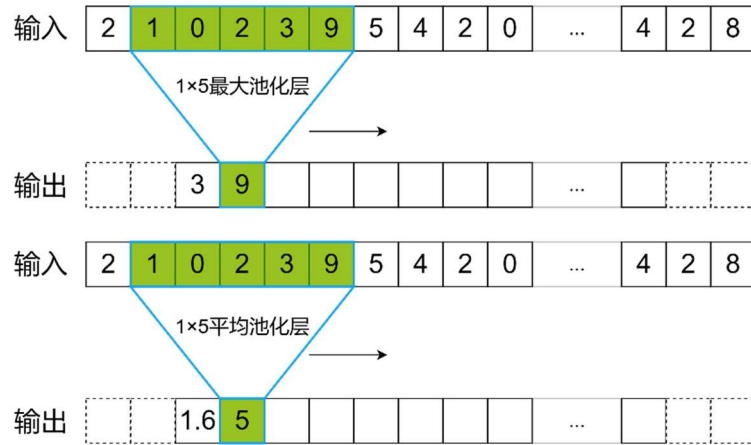


图 2-9 池化过程

池化层的关键参数，如池化窗口大小用于确定池化操作的局部感受野，步长确定池化窗口滑动的间隔，减小特征映射的宽度和高度。此外，池化层也可以与卷积层类似，使用填充来控制输出特征映射的尺寸。

池化层通过降低特征映射的分辨率，帮助网络学习到更高层次的抽象特征，同时减少网络的参数数量，降低过拟合的风险。其通常位于卷积层之后，在卷积层提取特征后，池化层可以进一步降低特征维度，为后续的卷积层或全连接层做准备。

2.2.3 编码器与解码器

U-Net 是一种流行的深度学习模型，最初设计用于生物医学图像分割任务。U-Net 的结构由一个编码器（下采样或收缩路径）和一个解码器（上采样或扩展路径）组成，形成一个 U 形结构（图 2-10）。

编码器部分由多个卷积层和池化层组成，每个卷积层后面通常跟着一个激活函数，如 ReLU。捕捉输入图像的上下文信息并逐步减少数据的空间维度（即宽度和高度）。一个编码器一般包含卷积层、池化层和跳跃连接（Skip Connection）。其中，跳跃连接实现了将编码器的输出直接连接到解码器对应层，帮助模型恢复丢失的空间信息。

解码器部分由一系列上采样（或转置卷积）层组成，用于逐步恢复图像的空间分辨率。在上采样之后，通常会有卷积层进一步细化特征图。跳跃连接帮助 U-

Net 模型的解码器在每个层次将编码器对应阶段的特征图与解码器的特征图进行拼接，恢复数据的细节信息。

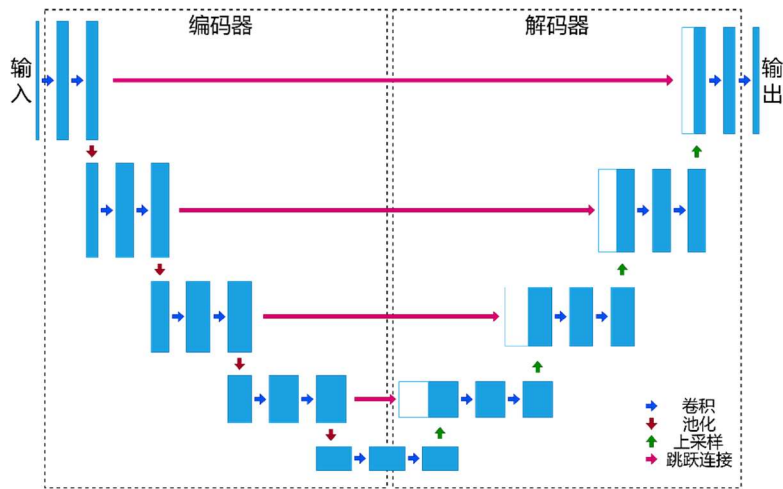


图 2-10 U-Net 结构

U-Net 的跳跃连接将编码器的高分辨率特征和解码器的高抽象特征结合，特别适合于需要精确定位的图像分割任务且无需额外的特征工程，这种独特的结构使其在图像分割领域非常成功，尤其是在医学图像处理中，如细胞分割、器官定位等任务，因此 U-Net 可以考虑用于一维生物信号分割，比如本文涉及的胎心率信号。

2.3 本章小结

本章深入探讨了胎心宫缩监护的理论基础和深度学习在该领域的相关知识。

本章节首先介绍了胎心宫缩信号的采集方式，包括非侵入性的外监护和更精确的内监护技术。通过这些方法，反映胎儿健康状况的关键信息可以被获取。其次，本章节概括了胎心宫缩信号的波形特征，包括基线心率、变异性、加速和减速等，这些特征对于评估胎儿是否遭受缺氧或其他并发症至关重要。此外，本章还介绍了胎心宫缩信号的状态分类，如正常、可疑和异常模式，这些分类为临床决策提供了重要依据。

在深度学习模型介绍部分，本章节详细阐述了构建深度神经网络的关键层：卷积层、池化层和全连接层。卷积层通过局部感受野提取特征，池化层降低特征

维度并增加不变性，全连接层则用于高级特征处理和分类。此外，本章介绍了 U-Net 这种专门为图像分割设计的网络，其编码器-解码器结构有效结合了图像的细节和上下文信息。

最后，我们总结了深度学习在胎心宫缩信号分析中的潜力，尤其是在提高信号解读的准确性和效率方面的应用。深度学习模型，如 U-Net，通过其强大的特征提取能力，有助于更好地理解 and 分类胎心宫缩信号，从而为围生期监护提供更有力的工具。

3. 基于深度神经网络的基线确定算法研究

3.1 研究流程设计

在本研究中，我们采用一种改进的深度神经网络模型来自动确定胎心率基线，旨在提高胎心监护的准确性和效率。本研究首先需要对现有的胎心率基线确定技术进行深入的文献回顾，探讨深度学习在生物信号处理领域的应用进展，并确定深度学习在自动确定胎心率基线方面应用的可行性；确定研究目标后，定义基线确定算法的目标和性能指标；接下来，收集适用的数据集并进行降噪、插值等预处理，尽可能使用不损失时序信息的处理方法；设计深度神经网络架构，确定模型的输入输出格式；使用预处理后的数据训练深度学习模型，采用交叉验证等方法评估模型性能；分析模型学习到的特征，调整模型参数和结构以提高性能；同时尝试应用正则化、**dropout** 等技术减少过拟合；使用独立的测试集评估模型的准确性、灵敏度和特异性，并设计消融实验确定各模块的有效性以及使用独立数据集测试该模型的泛化能力。

3.2 实验数据预处理

3.2.1 数据集介绍

CULF-DB 由产科医生从法国里尔圣文森特德保罗医院产科诊所 2011 年至 2016 年记录的 12000 例分娩中选择而来^[31]，一共 156 条 FHR 记录，每条记录包含胎心率信号、宫缩信号以及专家绘制的基线（见图 3-1），其中 66 条含标签的 FHR 记录（训练数据集）和 90 条未公开标签的 FHR 记录（评估数据集）。标记数据集的目的是使研究人员能够评估他们的自动分析方法并将其与专家共识进行比较。156 条记录中的每一个都经过四位专家的评估和标签商定。信号以 4Hz 的频率采样，训练数据集的平均长度为 90 分钟（30 分钟到 7 小时），而评估数据集的平均长度为 105 分钟（90 到 120 分钟），胎心率的三种模式分布见图 3-2。评估数据集由三种类型的记录组成：简单、中级和困难，每种类型有 30 个录音。这个独立的数据集用于测试方法，实验结果必须交给法国研究员测试，由法国研

究人员根据测试结果实时更新排行榜，以保持公平性。




图 3-1 CTG 数据图像

考虑到过拟合问题，本研究拟使用多个数据集对模型进行评估，测试其泛化能力。CTU-CHB^[32]数据库包含 552 条原始 FHR 和 UC 信号，每条信号持续时长为 30~90 分钟，其中信号的采样频率为 4Hz。这些胎心宫缩监护记录由杰克共和国布尔诺大学医院收集并按照临床标准精心挑选而来，记录时间从 2021 年 4 月到 2012 年 8 月。每条附带孕妇的生理指标和其他临床数据，如表 3-1 所示，这些参数指标对在 CTG 信号的智能评价中有着重要的参考作用。

表 3-1 CTU-CHB 数据集提及的附加参数

孕产妇危险因素	年龄、妊娠、产次、高血压、发热、糖尿病、先兆子痫、胎便、液化、早发；
分娩数据	阴道分娩、手术分娩和剖腹产；
胎儿数据	性别、出生体重；
结果数据	pH、BDecf、BE、Apg1、Apgar 评分、pCO2、pO2、需氧量、癫痫发作和入住新生儿重症监护病房(NICU)。

Sofia 等人使用 CTG Analyzer 解读 CTU-CHB 数据集中的 FHR 信号^[33]，提供了一个高质量的注释数据集，可作为数字 CTG 研究的金标准。注释包括检测 FHR 信号和产妇宫缩图中特定 CTG 事件的起始和结束点，子宫收缩。数据集还报告了每次减速的分类，包括与子宫收缩相关的早期、晚期、变异性或延长型减速。




图 3-2 CULF-DB（左）和 CTU-CHB（右）中基线/加速/减速模式的分布

3.2.2 数据异常值预处理

通过多普勒超声（US）在外部测量胎心率比内部测量胎心率的信噪比低，这些伪影可能由母体或胎儿、超声波探头的移动或仅仅是记录设备对胎儿心跳的误检测导致的。本研究采用一种简单的伪影消除方案：令 $l(i), i = 1, 2, \dots, N$ 为以每分钟节拍数 (bpm) 为单位的 FHR 信号，其中 N 是采样点数。当 $l(i) \leq 50$ 或 $l(i) \geq 200$ 时，这些采样点将被删除。当丢失的信号长度小于或等于 15 秒，本文采用 Hermit 三次样条插值法填充缺失值，长间隙的数据缺失将被忽视。处理前后如图 3-3 所示。

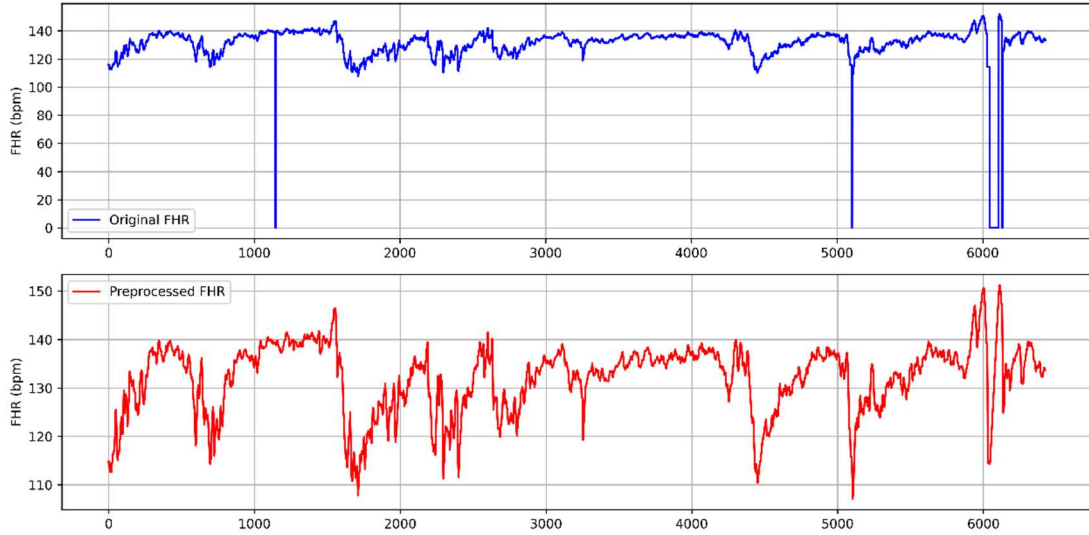


图 3-3 外测量胎心率异常值处理

对于 CTU-CHB 数据集，原始 CTG 数据包含由于数据丢失导致的伪影，且胎心率模式的注释依赖临床医生的主观判断，难以得到准确的注释。所以本文将结合 Sofia 团队利用 CTG Analyzer 识别出的 FHR 信号中的加速减速事件，利用基线的定义画出 FHR 信号的基线作为伪标签，再对 FHR 信号和 UC 信号进行降噪等处理。详细处理流程如图 3-4 所示。

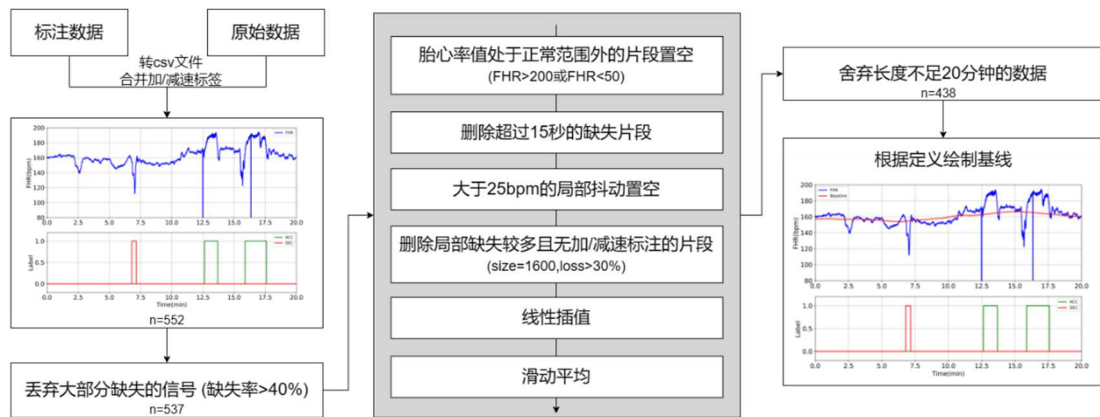


图 3-4 CTU-CHB 数据预处理流程

3.2.3 数据增强方法

由于数据集提供的胎心率记录时间跨度差异较大，持续时长从 30 分钟到 15 小时不等，本研究采取两个步骤扩充并增强数据，如图 3-5 所示。本文首先采用滑动窗口采样的方式，对整条的胎心率信号进行切片，以得到持续时长相等的一

系列胎心率信号片段。窗口长度设置为 20 分钟即 4800 个采样点，滑动步长为 1600 个采样点。当窗口滑动到信号末端时，不一定滑满步长，故而直接从信号末端开始采集 4800 个采样点。

上述过程一定程度上扩充了数据，在此基础上，本文将对加速和减速模式下的信号点进行缩放，达到数据增强的效果。最后，上述信号子片段用来构建训练和测试数据集，为了确保评估的可靠性，在训练数据集和测试数据集分离后再进行滑动窗口采样和数据增强。

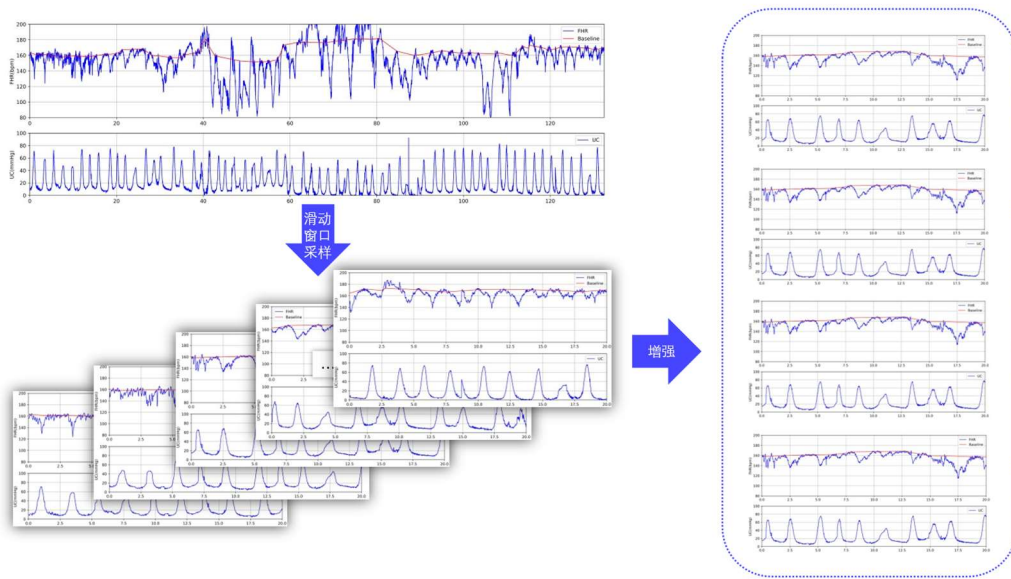


图 3-5 胎心率信号的滑动窗口采样和子片段的数据增强

3.3 算法模型设计

本研究基于 U-Net 架构进行改进，使其适用于胎心率信号分割任务，如图 3-6 (a) 所示。该编码器具有一个卷积块、一个多尺度特征提取 (MSE) 模块和一个 1×2 最大池化操作 (步幅为 2) 用于下采样。解码器使用 5 层卷积，上采样因子为 2，对压缩的特征向量进行上采样。解码器中的每个步骤都将跳跃连接与编码器中相应的裁剪后的特征图集成在一起。如图 3-6 (b) 所示，卷积块应用 1×65 卷积，每个卷积后面跟着批量归一化、dropout 层和 LeakyReLU 激活。MSE 模块 (见图 3-6 (c)) 比跳过连接更明确地捕获跨多个尺度的 FHR 趋势。它采用不同内核大小的卷积来提取不同感受野尺度的特征。然后将这些不同尺度的特

征连接起来形成一个多尺度特征图，便于长期和短期信号形态分析。

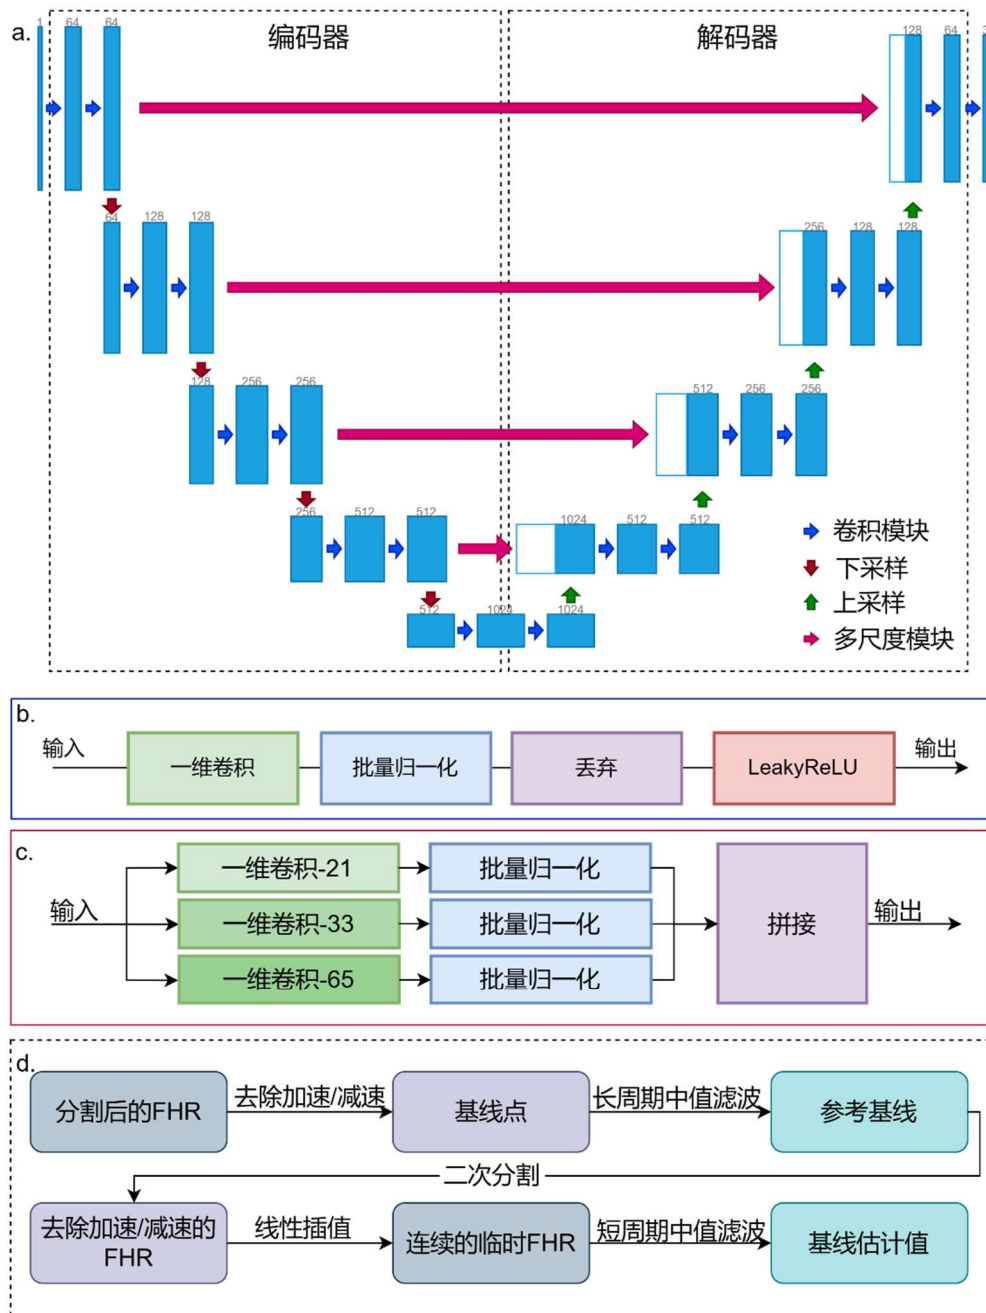


图 3-6 本研究提出的方法示意图 (a) MseUNet 模型结构; (b) 卷积模块; (c) 多尺度特征提取模块; (d) 分割结果的后处理

基线是通过从胎心率记录中排除加速度和减速度来确定的，这些加速度和减速度定义为分别超过或低于基线 15 秒以上的偏差。最终基线确定的流程如图 3-6 (d) 以及图 3-7 所示，给定基线的循环定义，对 MseUNet 子段的预测进行过滤以消除加速点和减速点。使用剩余点的全局中值滤波器计算初步基线。如果基

线点占数据的比例少于 10%，则将其替换为线性插值，以防止出现不准确的情况。随后，根据该初步基线识别并删除新的加速点和减速点。然后通过线性插值估计缺失值，形成新的胎心率信号。最终基线是使用 5 分钟中值滤波窗口根据加速、减速和基线三种模式的定义确定的。此过程可确保准确确定基线，平衡全局和局部胎心率信号趋势。




图 3-7 基于长短周期滤波的基线确定算法

3.4 本章小结

本章详细介绍了基于深度神经网络的胎心率基线确定算法的研究流程设计。

首先,通过深入的文献回顾,本文探讨了深度学习在自动确定胎心率基线方面的可行性,并确定了研究目标和模型结构。接着,本文对 CULF-DB 数据集进行了详尽的介绍,包括其构成、特点以及数据预处理的重要性。在数据预处理部分,本研究采用了多种技术,包括去噪、插值和异常值处理,以确保数据的质量和模型训练的有效性。此外,本研究还采用了数据扩充算法,通过滑动窗口采样和信号点缩放来增加数据多样性,从而为训练模型提供更多有效的数据,并且增加扰动提高模型的泛化能力。在算法模型设计方面,我们基于 U-Net 架构进行了改进,设计了一个适应于胎心率信号分割任务的深度神经网络模型。该模型结合了编码器和解码器结构,并通过多尺度提取模块来捕获不同尺度的 FHR 趋势。我们还介绍了基线的计算方法,包括使用中值滤波器和线性插值来精确确定胎心率基线。

4. 实验与分析

4.1 性能评估指标

为了验证自动分析方法和专家分析之间的一致性,有五个指标用于对局部特征和全局特征之间的差异进行量化。

局部特征包括基线、加速度和减速度。预测的基线与专家评定的基线的均方根差 (RMSD) 通常用于验证平均基线差异 (以 bpm 为单位):

$$BL.RMSD(BL.P - BL.E) = \sqrt{\frac{\sum_{i=1}^n (BL.P_i - BL.E_i)^2}{n}} \quad (4-1)$$

其中 BL.P 和 BL.E 分别是我们的方法预测的基线和专家注释的基线, n 是信号的数量。此外,加速或减速的 F-measure (Acc/Dec. F-measures) 计算如下:

$$F - measure = \frac{2TP}{2TP + FP + FN} \quad (4-2)$$

其中 TP 表示真阳性的数量, FN 和 FP 分别是假阴性和假阳性的数量。




图 4-1 胎心率信号分割混淆矩阵

在三分类的情况下 (图 4-1), $Acc.F - measure = \frac{2 \times e}{2 \times e + b + h + d + f}$, 其中 b 与 h 的和为假阳性, d 与 f 是假阴性; $Dec.F - measure = \frac{2 \times i}{2 \times i + f + c + g + h}$, 其中 f 与 c

的和为假阳性，g 与 h 是假阴性。

全局特征由综合不一致性系数（SI）^[34]和形态分析不一致指数（MADI）^[35]评估。SI 概括了加减速事件的整体质量，因为它考虑了加减速事件的三个方面（面积、位置和数量），并对应于加减速表面差值的百分比。它的计算方式为加速度综合不一致性（ASI）和减速度综合不一致性（DSI）的加权平均值，如下所示：

$$SI = \frac{ASI + 2DSI}{3} \quad (4-3)$$

$$ASI = \sqrt{\frac{\sum_{i=1}^A (Acc.P_i - Acc.E_i)^2}{\sum_{i=1}^A \max(Acc.P_i, Acc.E_i)^2}} * 100\% \quad (4-4)$$

$$DSI = \sqrt{\frac{\sum_{i=1}^D (Dec.P_i - Dec.E_i)^2}{\sum_{i=1}^D \max(Dec.P_i, Dec.E_i)^2}} * 100\% \quad (4-5)$$

其中 A 和 D 分别是方法和专家预测的加速和减速次数。Acc.P 和 Acc.E 分别表示由网络和专家检测到的加速 i 的区域，而 Dec.P 和 Dec.E 分别表示由网络和专家检测到的减速 i 的区域。若该方法未检测到加速/减速，则 Acc.P/Dec.P 设置为 0。

MADI 旨在估计 BL.P 和 BL.E 在真实胎心率方面不一致的时间百分比。当两个基线差异很大时，它们是不一致的，因此在检测加速/减速事件时存在差异。MADI 由以下等式定义：

$$MADI = \frac{1}{n} \sum_{i=1}^n \frac{(BL.P_i - BL.E_i)^2}{(D_{FHR}^{BL.P})_i \times (D_{FHR}^{BL.E})_i + (BL.P_i - BL.E_i)^2} \quad (4-6)$$

$$(D_{FHR}^x)_i = \alpha + \sqrt{\frac{\sum_{j=i-120}^{i+120} (x_j - FHR_j)^2}{240}} \quad (4-7)$$

其中 n 是 FHR 记录的总数（全部以每分钟 240 个点采样，即 4 Hz）和 D_{FHR}^x 对应于当前样本周围 1 分钟内的平均 FHR 变异性（以基线 x 作为参考）。它大约相当于当有一个时，局部变异性（FHR 超过 1 分钟的标准偏差）和事件振幅（平均 FHR 与基线之间的差值）。 α 是一个常数（设置为 3 bpm），添加以抵消当变异

性时的最小值 FHR 为零或几乎为零。

4.2 与其他方法对比

4.2.1 其他方法介绍

在胎心率基线确定方面已经有许多种可行的方法，并且 Houzé de l’Aulnoit 等人^[36]已经将这 11 种方法使用 MATLAB 编程实现，集成在 FHRMA 工具包中。

表 4-1 11 种确定胎心率基线传统方法描述

作者及文献出处	基线计算方法
Ayres-de Campos et al. ^[37]	基于十分钟的滑动窗口中最频繁的 FHR 值确定。
Cazares et al. ^[11]	基于形态学进行滤波器，开式滤波器消除加速度，闭式滤波器消除减速度。
Houzé de l’Aulnoit et al. ^[38]	对 FHR 信号的导数进行一系列逻辑判断，在进行平滑处理。
Jimenez et al. ^[12]	不稳定周期（导数高于阈值）的信号被去除，然后在平滑剩余信号后计算基线。
Lu and Wei ^[39]	使用经验模态分解的方法。两个连续的局部胎心率最小值之间表现出显著差异的时段被排除在基线计算之外。
Maeda et al. ^[19]	基线设置为最常出现在 10 bpm 宽区间内的胎心率的值。
Mantel et al. ^[9]	首先使用 FHR 信号的分布直方图得到众数或一个局部最大值作为初始基线，然后对它逐步修剪得到最终基线。
Mongelli et al. ^[18]	计算主模和次模，且根据连续性和频率标准切换。
Pardey et al. ^[13]	首先取 FHR 信号的分布直方图中的众数或另一个局部最大值作为初始基线，然后对它逐步修剪得到最终基线。
Taylor et al. ^[10]	使用渐进式修剪的线性低通滤波。
Wróbel et al. ^[40]	均衡线性均值滤波和模式识别的方法。

4.2.2 实验设置

本研究通过 Python 在 PyTorch 框架上实现深度神经网络模型，以探索和解解决特定的机器学习问题。PyTorch 是一个开源的机器学习库，广泛用于计算机视觉和自然语言处理任务，它提供了强大的 GPU 加速和动态计算图，使得模型训练和实验迭代更加高效。为了确保实验的可复现性，研究中使用的具体环境配置和软件版本被详细记录在表 4-2 中。

表 4-2 实验环境及具体参数

实验环境	配置参数
操作系统	Ubuntu 20.04.2
开发语言	Python 3.9.16
深度学习框架	PyTorch 1.12.0
开发工具	PyCharm
CPU	Intel Xeon 4210
GPU	NVIDIA RTX 4090 GPU
内存	128 GB

模型训练使用了公开 CTG 数据库 CLUF-DB^[41]（包含 66 条带标签的 FHR 记录），其中数据集在预处理后按 7：2：1 的比例分割训练、验证以及测试集，并对分割后的子数据集进行数据增强。训练时使用 AdamW^[42]作为优化器，初始学习率为 0.00001。训练迭代数设置为 100，批量（batch size）大小为 32。损失函数为自定义的损失函数，可用如下公式表示：

$$Loss = -\log Acc.FScore - \log Dec.FScore - \log BL.FScore \tag{4-8}$$

$$FScore = 2 \times (Precision * Recall) / (Precision + Recall) \tag{4-9}$$

Precision（精确度）表示预测为正类的样本中，实际为正类的比例，计算公式为： $Precision = TP / (TP + FP)$ ；Recall（召回率）表示正确预测为正类的样本占有所有实际为正类的样本的比例，计算公式为： $Recall = TP / (TP + FN)$ 。即真实值为基线状态且预测结果为基线的采样点记作 TP，FP 表示预测为基线模

式，实际上并非基线的点，FN 表示实际为基线但未被识别为基线的点。

4.2.3 实验结果对比分析

为了评估本研究所提出的自动确定方法和专家分析之间的一致性，在此采用均方根差（RMSD）来量化基线之间的差异，加速或减速的 F-measure 来衡量模型确定的基线对加速或减速模式的划分能力。由表 4-3 可见，本文提出的方法（Ours）在 BL.RMSD 上表现最佳，仅为 3.20 bpm，远低于其他所有传统方法，这表明所提出的方法在自动确定基线方面与专家分析的一致性非常高。在减速的 F-measure 上，提出的方法（Ours）得分为 0.75 这是表中最高的分数，表明该方法在识别减速模式方面的性能非常出色；在加速的 F-measure 上，Lu 等人^[39]的方法得分最高（0.70），而提出的方法（Ours）以 0.59 的得分位列中等偏上。SI 为 55.3%，MADI 为 4.96%，综合不一致性和形态分析不一致都是表中最底的，可见模型预测和专家分析之间的平均差异非常小。所估计的基线划分加/减速效果见图 4-2。

表 4-3 不同方法在 CULF-DB 上的性能表现

方法	BL.RMSD (bpm)	Dec. F-measure	Acc. F-measure	SI (%)	MADI (%)
Ayres-de ^[37]	5.6	0.68	0.64	71	12.2
Cazares ^[11]	6.1	0.67	0.54	69	20.4
Houze ^[12]	6.0	0.71	0.59	69	10.9
Jimenez ^[38]	7.8	0.61	0.55	77	14
Lu ^[39]	4.0	0.73	0.70	62	7.3
Maeda ^[19]	5.7	0.66	0.58	71	15
Mantel ^[9]	4.7	0.69	0.65	64	12.6
Mongelli ^[18]	5.1	0.67	0.57	69	11.8
Pardey ^[13]	4.7	0.69	0.61	63	13.2
Taylor ^[10]	6.7	0.68	0.57	82	11.5
Wrobel ^[40]	5.0	0.67	0.67	65	11.7
Ours	3.2	0.75	0.59	55.3	4.96

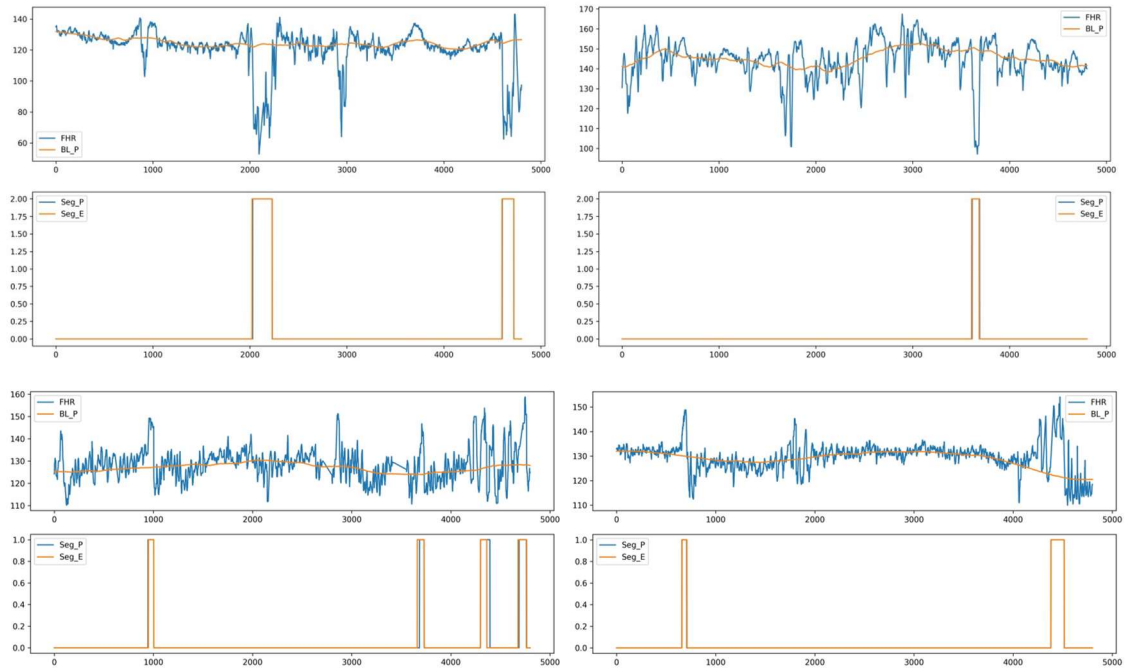


图 4-2 CULF-DB 上 20 分钟 FHR 信号的基线确定以及加速和减速模式分析示例

为验证模型的泛化能力，本研究从 CTU-CHB 中随机挑选 200 条数据运用该模型确定基线，实验结果中，BL.RMSD 为 3.54，模型在该数据集上估计基线的效果与定义的结果较为一致。所估计的基线划分加/减速效果如图 4-3 所示。

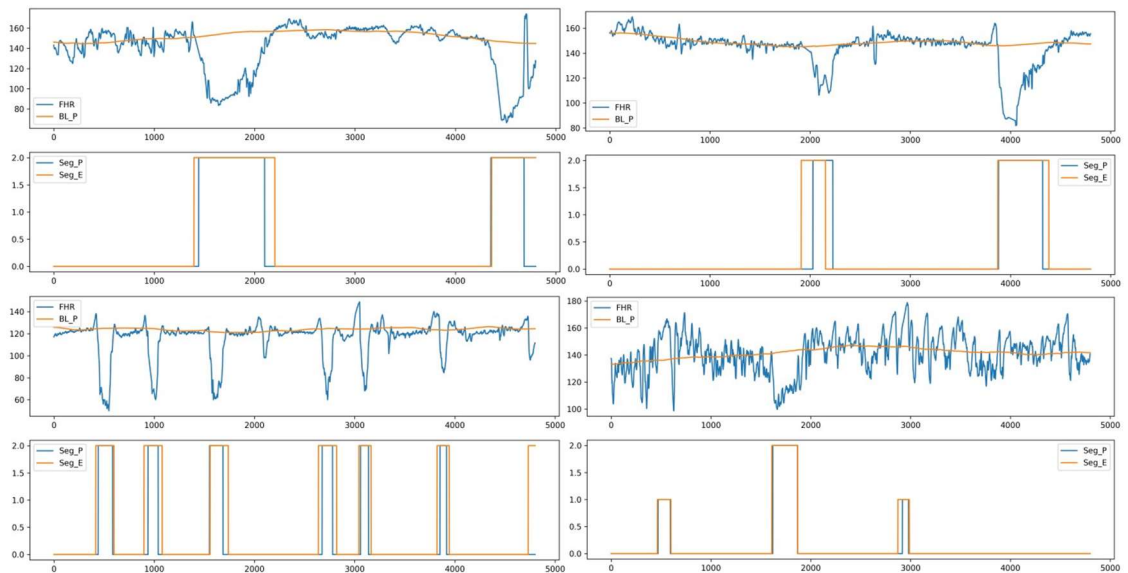


图 4-3 CTU-CHB 上 20 分钟 FHR 信号的基线确定以及加速和减速模式分析示例

4.3 消融实验

4.3.1 实验设计

为评估模型中各个组件的贡献，本小节将记录移除或修改部分组件，对模型整体性能的影响。本研究的消融实验将着重关注两个方面：多尺度特征提取模块中卷积核大小以及损失函数各模块权重。

多尺度特征提取模块被纳入 MscUNet 以提高分割精度。受 Zhou 等人^[43]的研究的启发，长卷积对长周期的胎心率信号研究有不同程度的精度上的正向影响，参考他们的结论，本研究拟采用 21, 31, 61, 81 这几个卷积核尺寸的组合测试卷积核尺寸搭配对模型性能的影响，同时，使用跳跃连接的原始 U-Net 将作为空白对照。

由于加速、减速和基线模式的分布不平衡，该模型在分割时遇到数据不平衡的问题。自定义损失函数各部分的权重设置用于优化不平衡三类分割（即基线、加速和减速）中的 F-measure。本章节的实验，将对不用权重的组合挖掘最优的分割权重。

4.3.2 结果分析

表 4-4 多尺度特征提取模块以及各卷积核尺寸对模型性能的影响

Kernel-Size	BL.RMSD (bpm)	Acc. F-measure	Dec. F-measure	MADI (%)	SI (%)
U-Net	3.47	0.57	0.69	4.97	55.4
[21,31,61]	3.50	0.58	0.73	4.97	56.8
[21,31,81]	3.42	0.56	0.75	4.97	58.3
[21,61,81]	3.32	0.58	0.75	4.97	58.1
[31,61,81]	3.20	0.59	0.75	4.96	55.3

表 4-4 总结了多尺度特征提取模块以及其中的各卷积核尺寸对方法性能的影响。引入多尺度特征提取模块后，与基本的 U-Net 模型相比，模型在 BL.RMSD、

Acc. F-measure 和 Dec. F-measure 上均显示出性能提升，这表明多尺度特征提取有助于更准确地确定基线并分辨加速/减速事件。在 MADI 指标上，所有多尺度模型都显示出与 U-Net 相似或更好的性能，表明它们在评估不一致性方面同样有效或更优。SI 指标（综合不一致性）在所有多尺度模型中都有所提高，这表明模型对加减速事件的整体质量评估更为一致，尤其是在使用[31, 61, 81]卷积核尺寸时，SI 达到了最高值 58.3%。

通过比较不同卷积核尺寸组合的模型性能，可以看出，随着卷积核尺寸的增加，模型在局部特征性能上有所提升，尤其是在 Dec. F-measure 上。最优的卷积核尺寸组合为[31, 61, 81]，它在 BL.RMSD 上达到了最低值 3.20，同时在 Dec. F-measure 上达到了最高值 0.75，几乎在所有评估指标上都显示出了最优性能，这表明该组合在提取不同尺度的特征时最为有效。

此外，本次实验结果表明，多尺度特征提取是改进 FHR 信号分析的有效策略，它能够捕获不同尺度的特征，从而提高模型对 FHR 信号的理解。

表 4-5 损失函数的不同权重组合模型性能的影响

Weight	BL.RMSD (bpm)	Acc. F-measure	Dec. F-measure	MADI (%)	SI (%)
Cross-Entropy	3.68	0.58	0.72	4.98	45.1
[1,6,8]	3.70	0.57	0.74	4.97	60.9
[1,1,1]	3.70	0.57	0.74	4.97	54.2
[0,1,1]	3.45	0.58	0.74	4.98	62.9
[0.5,1,2]	3.59	0.58	0.74	4.97	55.1
[1,1,2]	3.79	0.58	0.74	4.98	59.3
[0,1,3]	3.35	0.56	0.75	4.98	67.1
[0,1,2]	3.20	0.59	0.75	4.96	55.3

损失函数对模型性能的影响如表 4-5 所示。与仅使用交叉熵损失函数的模型相比，所有自定义损失函数的模型在 BL.RMSD、Acc. F-measure 和 Dec. F-measure 等指标上均展现出了更好的性能或相似的性能，这表明自定义损失函数能够更有

效地训练模型以适应特定的任务需求。权重组合对模型性能有显著影响。特别是，当基线的权重降低，而加速和减速的权重增加时，模型在确定基线和识别加减速事件上的性能得到了提升。

在所有测试的权重组合中， $[0, 1, 2]$ 权重组合在 BL.RMSD 上表现最佳，达到了 3.20 bpm，同时在 Dec.F-measure 上也表现优异，为 0.75。这表明该权重组合在分割确定基线和识别减速事件上更为有效。

此外，结合数据集的三种模式的分布（图 3-2）可知，当损失函数权重组合与数据中真实模式的分布更加匹配时，模型性能更佳。为进一步优化损失函数，可考虑引进自适应模式分布的模块，切实应考虑数据的实际分布情况。

4.4 本章小结

本章节通过一系列精心设计的实验步骤，全面评估了我们提出的基于深度神经网络的胎心率（FHR）基线确定算法。在实验的初始阶段，我们明确了性能评估的指标，这些指标包括局部特征（如基线、加速度和减速度）和全局特征（如综合不一致性系数 SI 和形态分析不一致指数 MADI），旨在从不同角度细致评估模型性能。

本次实验采用了自定义的损失函数，利用公开的 CLUF-DB 数据集对模型进行了训练。通过与 11 种传统方法的对比实验，本研究提出的模型在均方根差（RMSD）这一关键性能指标上展现了显著的优越性。特别是在减速事件的分割上，该模型表现出了较好的性能，而在加速模式的区分上，尽管已经取得了一定的成果，但仍有改进的空间。此外，该模型在 CTU-CHB 数据集上的表现，证明了其具有一定的泛化能力。

实验结果不仅证实了本研究所提出方法的有效性，而且在临床应用的背景下，为未来的研究方向提供了有力的支持。该深度学习模型通过自动分析 FHR 信号，展现了在自动胎心监护分析中的潜力，这为提高胎儿健康监测的智能化水平提供了新的途径。

此外，本章节的实验结果还突出了自定义损失函数在模型训练中性能提升的

重要性, 以及如何通过调整损失函数的权重来优化模型对特定类型事件的识别能力。这一发现对于设计和训练针对特定医疗信号分析任务的深度学习模型具有重要的启示意义。

5. 总结与展望

本文提出了一种创新的方法，用于自动确定胎心率（FHR）信号的基线，增强胎心率信号分析。这一方法的核心在于利用多尺度提取技术和长期短期中值滤波器，以实现 FHR 信号全局和局部趋势的平衡分析。这种方法不仅考虑了信号的局部特征，如瞬时变化和短期波动，还兼顾了长期趋势和整体模式，从而提高了基线确定的准确性和可靠性。这一平衡分析策略的应用，使得我们能够在不同尺度上捕捉 FHR 信号的细微变化，为胎儿健康状况的监测提供了更具可解释性且符合形态学特征的信息。

实验结果表明，本研究所提出的方法在 CULF-DB 数据集上表现出色，其中模型在基线 RMSD 上达到了 3.20 bpm 的优异性能，此外，模型确定的基线在减速模式辨别上展现了最佳的效果，但在加速模式的区分上还有改进的空间。这些结果不仅验证了该方法的有效性，也为未来的研究和临床应用提供了有力的支持。

未来，本研究将致力于探索将子宫收缩（UC）信号整合到分析框架中。通过这种方式，我们希望能够更准确地识别和分类 FHR 信号中的早期、中期或变异减速，从而为胎儿窘迫的诊断提供更加精确的依据。同时，设计一个多变量时间序列模型，该模型将能够处理和分析复杂的 FHR 和 UC 信号之间的相互作用，同时计划设计一个基于先前分类模型的卷积模块，用于胎心监护（CTG）信号的质量评估。这一模块将进一步提高我们方法的鲁棒性，确保在不同的临床场景下都能提供稳定可靠的分析结果。

最终，我们的目标是将这两个网络集成到一个多任务学习框架中，使得模型能够在执行多个任务时共享有用的特征表示，同时允许任务特定的参数调整。这种多任务学习方法不仅能够优化模型的参数共享，提高模型的泛化能力，还能够针对特定任务调整模型，以更好地捕捉 FHR 信号的关键特征。

通过这种方法，我们期望能够显著提升 FHR 信号的表示能力，为胎儿心率监测提供更加精确和深入的理解。这不仅将推动围产期医学的发展，也将为胎儿健康监测和临床决策提供强有力的工具。

参考文献

- [1] Evans M I, Britt D W, Evans S M, et al. Improving the interpretation of electronic fetal monitoring: the fetal reserve index[J]. American Journal of Obstetrics and Gynecology, 2023, 228(5, Supplement): S1129-S1143.
- [2] Jia Y J, Chen X, Cui H Y, et al. Physiological CTG interpretation: the significance of baseline fetal heart rate changes after the onset of decelerations and associated perinatal outcomes[J]. The Journal of Maternal-Fetal & Neonatal Medicine: The Official Journal of the European Association of Perinatal Medicine, the Federation of Asia and Oceania Perinatal Societies, the International Society of Perinatal Obstetricians, 2021, 34(14): 2349-2354.
- [3] Garabedian C, Butruille L, Drumez E, et al. Inter-observer reliability of 4 fetal heart rate classifications[J]. Journal of Gynecology Obstetrics and Human Reproduction, 2017, 46.
- [4] Cömert Z, Kocamaz A F. Fetal Hypoxia Detection Based on Deep Convolutional Neural Network with Transfer Learning Approach[M]. Software Engineering and Algorithms in Intelligent Systems: Vol. 763. Cham: Springer International Publishing, 2019: 239-248.
- [5] Li J, Chen Z Z, Huang L, et al. Automatic Classification of Fetal Heart Rate Based on Convolutional Neural Network[J]. IEEE Internet of Things Journal, 2019, 6(2): 1394-1401.
- [6] Fergus P, Chalmers C, Montanez C C, et al. Modelling Segmented Cardiotocography Time-Series Signals Using One-Dimensional Convolutional Neural Networks for the Early Detection of Abnormal Birth Outcomes[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2021, 5(6): 882-892.
- [7] Lv Q J, Chen H Y, Zhong W B, et al. A Multi-Task Group Bi-LSTM Networks Application on Electrocardiogram Classification[J]. IEEE Journal of Translational Engineering in Health and Medicine, 2020, 8: 1900111.
- [8] Liang H, Lu Y. A CNN-RNN unified framework for intrapartum cardiotocograph classification[J]. Computer Methods and Programs in Biomedicine, 2023, 229: 107300.

- [9] Mantel R, Van Geijn H P, Caron F J M, et al. Computer analysis of antepartum fetal heart rate: 1. Baseline determination[J]. International Journal of Bio-Medical Computing, 1990, 25(4): 261-272.
- [10] Taylor G M, Mires G J, Abel E W, et al. The development and validation of an algorithm for real-time computerised fetal heart rate monitoring in labour[J]. BJOG: An International Journal of Obstetrics & Gynaecology, 2000, 107(9): 1130-1137.
- [11] Cazares S, Tarassenko L, Impey L, et al. Automated identification of abnormal cardiotocograms using neural network visualization techniques[C]. Conference Proceedings of the 23rd Annual International Conference of the IEEE Engineering in Medicine and Biology Society: Vol. 2. 2001: 1629-1632 vol.2.
- [12] Jimenez L, Gonzalez R, Gaitan M, et al. Computerized algorithm for baseline estimation of fetal heart rate[C]. Computers in Cardiology. Memphis, TN, USA: IEEE, 2002: 477-480.
- [13] Pardey J, Moulden M, Redman C W G. A computer system for the numerical analysis of nonstress tests[J]. American Journal of Obstetrics and Gynecology, 2002, 186(5): 1095-1103.
- [14] Boudet S, Houzé de l'Aulnoit A, Demailly R, et al. Fetal heart rate baseline computation with a weighted median filter[J]. Computers in Biology and Medicine, 2019, 114: 103468.
- [15] Yamamoto H, Mitsukura Y. Automatic Deceleration Detection System from Fetal Heart Rate obtained by CTG[C]. IEEE 17th International Conference on Advanced Motion Control (AMC). Padova, Italy: IEEE, 2022: 346-351.
- [16] Fuentealba P, Illanes A, Ortmeier F, et al. Investigating an Optimal Signal Epoch Length for Cardiotocographic Classification[J]. Current Directions in Biomedical Engineering, 2020, 6(3): 514-517.
- [17] Ayres-de-Campos D, Rei M, Nunes I, et al. SisPorto 4.0 – computer analysis following the 2015 FIGO Guidelines for intrapartum fetal monitoring[J]. The Journal of Maternal-Fetal & Neonatal Medicine, 2017, 30(1): 62-67.

- [18] Mongelli M, Dawkins R, Chung T, et al. Computerised estimation of the baseline fetal heart rate in labour: the low frequency line[J]. BJOG: An International Journal of Obstetrics & Gynaecology, 1997, 104(10): 1128-1133.
- [19] Maeda K, Utsu M, Noguchi Y, et al. Central Computerized Automatic Fetal Heart Rate Diagnosis with a Rapid and Direct Alarm System[J]. The Open Medical Devices Journal, 2012, 4(1).
- [20] Saccone G, Tagliaferri S, Grasso A, et al. Antenatal cardiotocography with and without computer analysis in high-risk pregnancy: a randomized clinical trial[J]. American Journal of Obstetrics & Gynecology MFM, 2021, 3(1): 100284.
- [21] Haws R A, Yakoob M Y, Soomro T, et al. Reducing stillbirths: screening and monitoring during pregnancy and labour[J]. BMC Pregnancy and Childbirth, 2009, 9(1): S5.
- [22] Macones G A, Hankins G D V, Spong C Y, et al. The 2008 National Institute of Child Health and Human Development workshop report on electronic fetal monitoring: update on definitions, interpretation, and research guidelines[J]. Obstetrics and Gynecology, 2008, 112(3): 661-666.
- [23] Ayres-de-Campos D, Nogueira-Reis Z. Technical characteristics of current cardiotocographic monitors[J]. Best Practice & Research Clinical Obstetrics & Gynaecology, 2016, 30: 22-32.
- [24] RNC M M PhD. Antepartal and Intrapartal Fetal Monitoring: Third Edition[M]. Springer Publishing Company, 2006.
- [25] Parer J T. Benefits and detriments of fetal heart rate monitoring[J]. Seminars in Perinatology, 1978, 2(2): 113-118.
- [26] Ayres-de-Campos D, Spong C Y, Chandrachan E, et al. FIGO consensus guidelines on intrapartum fetal monitoring: Cardiotocography[J]. International Journal of Gynecology & Obstetrics, 2015, 131(1): 13-24.
- [27] Maeda K, Tatsumura M, Nakajima K, et al. The ultrasonic Doppler fetal actocardiogram and its Computer processing[J]. 1988, 16(4): 327-332.
- [28] Besinger R E, Johnson T R B. Doppler recordings of fetal movement: Clinical correlation with

real-time ultrasound[J]. *Obstetrics & Gynecology*, 1989, 74(2): 277.

[29] DiPietro J A, Costigan K A, Pressman E K. Fetal movement detection: Comparison of the Toitu actograph with ultrasound from 20 weeks gestation[J]. *The Journal of Maternal-Fetal Medicine*, 1999, 8(6): 237-242.

[30] 程志厚, 宋树良. 胎儿电子监护学[M]. 胎儿电子监护学, 2001.

[31] De l'Aulnoit A H, Boudet S, Demailly R, et al. Baseline fetal heart rate analysis: eleven automatic methods versus expert consensus[J]. *Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE Engineering in Medicine and Biology Society. Annual International Conference*, 2016, 2016: 3576-3581.

[32] Chudáček V, Spilka J, Burša M, et al. The CTU-UHB Intrapartum Cardiotocography Database[DS]. *physionet.org*, 2014.

[33] Romagnoli S, Sbröllini A, Burattini L, et al. Annotation dataset of the cardiotocographic recordings constituting the “CTU-CHB intra-partum CTG database”[J]. *Data in Brief*, 2020, 31: 105690.

[34] Jezewski J, Horoba K, Roj D, et al. Evaluating the fetal heart rate baseline estimation algorithms by their influence on detection of clinically important patterns[J]. *Biocybernetics and Biomedical Engineering*, 2016, 36(4): 562-573.

[35] Boudet S, Houzé l'Aulnoit A, Demailly R, et al. A fetal heart rate morphological analysis toolbox for MATLAB[J]. *SoftwareX*, 2020, 11: 100428.

[36] Houzé de l'Aulnoit A, Boudet S, Demailly R, et al. A comparison of 11 methods[J]. *Biomedical Signal Processing and Control*, 2019, 49: 113-123.

[37] Ayres-de Campos D, Bernardes J, Garrido A, et al. SisPorto 2.0: a program for automated analysis of cardiotocograms[J]. *The Journal of Maternal-Fetal Medicine*, 2000, 9(5): 311-318.

[38] Houze De L'Auinoit D L, Beuscart R J, Brabant G, et al. Real-time Analysis Of The Fetal Heart Rate[C]. *Proceedings of the Twelfth Annual International Conference of the IEEE*

Engineering in Medicine and Biology Society. Philadelphia, PA, USA: IEEE, 1990: 1994-1995.

[39] Lu Y, Wei S. Nonlinear baseline estimation of FHR signal using empirical mode decomposition[C]. IEEE 11th International Conference on Signal Processing. Beijing, China: IEEE, 2012: 1645-1649.

[40] Wróbel J, Horoba K, Pander T, et al. Improving fetal heart rate signal interpretation by application of myriad filtering[J]. Biocybernetics and Biomedical Engineering, 2013, 33(4): 211-221.

[41] Boudet S, Houzé de l'Aulnoit A, Demailly R, et al. FHRMA dataset[M]. 2019.

[42] Loshchilov I, Hutter F. Fixing Weight Decay Regularization in Adam[J]. 2018.

[43] Zhou Z. Identifying fetal status with fetal heart rate: Deep learning approach based on long convolution[J]. Computers in Biology and Medicine, 2023.

致谢

随着这篇学位论文的最后一个句点轻轻落下，我的内心涌动着深深的感激和无尽的温情。在此，我要向我的导师吕副教授表达最深切的敬意和谢意。在这段充满挑战的学术旅程中，您不仅是我智慧的灯塔，照亮了我前行的道路，更是我心灵的避风港，在每一个迷茫的十字路口给予我指引和安慰。您的耐心指导、深刻见解和无私支持，是我能够完成这篇论文的坚强后盾。

同时，我也要向大数据与互联网学院的授课老师和行政老师们致以诚挚的感谢。感谢你们在日常学习和升学方面给予我的帮助和支持，是你们的专业指导和悉心关怀为我提供了一个充满机遇的学习环境。

我还要特别感谢我的家人，他们始终是我学习和研究道路上的坚强后盾。在面对困难和挑战时，是家人的理解和支持，给了我坚持下去的勇气和力量。家的温暖和力量，是我不断前行的动力源泉。

此外，我要感谢我的室友们，感谢你们在这段旅程中的理解和支持。你们的包容和鼓励，为我提供了一个温馨的休息之所，让我在紧张的学习和研究之余，能够得到必要的放松和恢复。

我还要向实验室的师兄们表达我的感激之情。你们的经验分享、技术指导和生活上的关怀，让我在实验室的日子充满了学习和成长。你们不仅是我的榜样，也是我的朋友，感谢你们在这段旅程中的陪伴和帮助。

同样，我的同学也在我的学术旅程中扮演了不可或缺的角色。感谢你们在学习和生活上的相互支持与鼓励。我们的讨论、合作和友谊，丰富了我的大学生活，也让我在学术上得到了宝贵的启发。

最后，我要感谢所有直接或间接支持我完成本科学业的人。是你们的帮助和鼓励让我能够走到今天。这份成就，同样属于你们每一个人。在此，我衷心地向所有给予我帮助和支持的人表示感谢，是你们共同的努力和付出，让这篇论文得以完成。

攻读学士学位期间研究成果

- [1] **Leya Li**, Yu Lu*. MSEU-Net: A Multi-Scale Deep Learning Framework for Precise FHR Baseline Determination. Proceedings of the 21st ACM International Conference on Computing Frontiers (ACM CF 2024), Ischia, Naples, Italy, May 7-9, 2024. (CCF C 类国际会议)
- [2] Zichang Yu, Yating Hu, Yu Lu*, **Leya Li**, Huilin Ge, Xianghua Fu. CTGGAN: Reliable Fetal Heart Rate Signal Generation Using GANs. Proceedings of the 2024 International Joint Conference on Neural Networks (IJCNN), Yokohama, Japan, June 30-July 5, 2024. (CCF C 类国际会议)